Laboratorio 1: Análisis de series de tiempo del ingreso de viajeros a Guatemala

Universidad del Valle de Guatemala · CC3084 – Data Science
Jorge Luis López — 221038 · 26 de julio de 2026

Resumen ejecutivo

Este trabajo analiza el ingreso mensual de viajeros internacionales a Guatemala entre enero de 2009 y junio de 2026. Después de auditar y limpiar 161,036 registros, se utilizó la suma de turistas y excursionistas como medida comparable durante todo el período, debido a cambios metodológicos que afectan las categorías Viajero y Cruceristas desde 2023. Se construyeron siete series mensuales: el total de visitantes, las tres vías de ingreso y las tres regiones geográficas con mayor volumen acumulado.

El análisis identificó tendencia, estacionalidad anual y una ruptura estructural causada por la pandemia. En 2020 el total de visitantes comparables disminuyó 74.4% respecto de 2019. La vía terrestre y América del Centro concentran la mayor parte del volumen, mientras que Europa presenta la mayor fuerza estacional y volatilidad relativa. Se compararon modelos ARIMA/SARIMA, seasonal naïve, suavizamiento exponencial, Holt–Winters y Prophet mediante AIC, BIC, MAE y RMSE. Los mejores resultados variaron según la serie, lo que demuestra que no existe un modelo único adecuado para todos los flujos migratorios.

1. Introducción

El ingreso de viajeros es un fenómeno temporal influido por temporadas vacacionales, condiciones económicas, conectividad, eventos extraordinarios y cambios institucionales. Comprender estos patrones permite anticipar la demanda de servicios, coordinar recursos en aeropuertos y fronteras y orientar estrategias de promoción turística.

El objetivo general del laboratorio es describir el comportamiento histórico de los viajeros internacionales que ingresan a Guatemala y construir modelos capaces de pronosticar su evolución mensual. Para lograrlo se realizó una auditoría del conjunto de datos, un análisis exploratorio, la construcción de series mensuales, pruebas de estacionariedad y la comparación de diferentes métodos de pronóstico.

1.1 Objetivos específicos

- Identificar los principales países, regiones, vías y fronteras de ingreso.
- Analizar tendencia, estacionalidad, volatilidad y el impacto de la pandemia.
- Construir la serie total y las series de las categorías Vía y Región dos.
- Determinar las transformaciones y diferenciaciones necesarias.
- Comparar modelos ARIMA/SARIMA con métodos alternativos.

• Seleccionar el mejor modelo para cada serie mediante métricas dentro y fuera de muestra.

2. Descripción y preparación de los datos

La base contiene 161,036 registros en formato largo y cubre 210 meses consecutivos, desde enero de 2009 hasta junio de 2026. Cada fila corresponde a una combinación de año, mes, vía, frontera, país o agrupación, región y tipo de viajero, junto con la cantidad estimada de personas.

Las variables principales son Año, Mes, Vía, Frontera, País, Región, Región dos, Regiones OMT, MCEO, Agrupación Residencia, Tipo de Viajero y Viajero. La variable Viajero contiene la cantidad de personas y puede presentar decimales porque algunos valores provienen de estimaciones expandidas.

2.1 Consideraciones metodológicas

La documentación advierte un cambio importante entre 2022 y 2023. La categoría Viajero disminuye por una modificación en la clasificación y exclusión de movimientos fronterizos frecuentes, mientras que los cruceristas dejan de aparecer en esta fuente desde 2023. Para evitar interpretar estos cambios como una caída real del turismo, las comparaciones temporales utilizan únicamente:

Visitantes comparables = Turistas + Excursionistas

La columna País también cambia de países individuales a agrupaciones de mercado desde 2023. Por ello, los rankings acumulados son útiles para describir concentración, pero las series de mercados pequeños no son perfectamente comparables durante todo el período.

2.2 Limpieza

Se normalizaron encabezados y espacios en las variables de texto, se validaron el año, mes y cantidad de viajeros, y se construyó una fecha mensual. No se encontraron valores faltantes, duplicados exactos ni cantidades negativas. Los valores cero se conservaron y los decimales no se redondearon.

Los valores extremos fueron identificados con el criterio del rango intercuartílico. Sin embargo, no se eliminaron porque las observaciones más altas correspondían a mercados y fronteras con grandes flujos y no existía evidencia de errores. Eliminarlas habría reducido artificialmente los totales.

3. Análisis exploratorio

3.1 Comportamiento temporal

El ingreso de visitantes muestra crecimiento antes de 2020, un patrón estacional anual y una ruptura abrupta durante la pandemia. El total comparable pasó de aproximadamente 4.13 millones en 2019 a 1.06 millones en 2020, una reducción de 74.4%. Posteriormente se observa una recuperación gradual, aunque 2025 todavía se encuentra aproximadamente 18.9% por debajo de 2019. El año 2026 contiene únicamente enero a junio y no debe compararse como año completo.

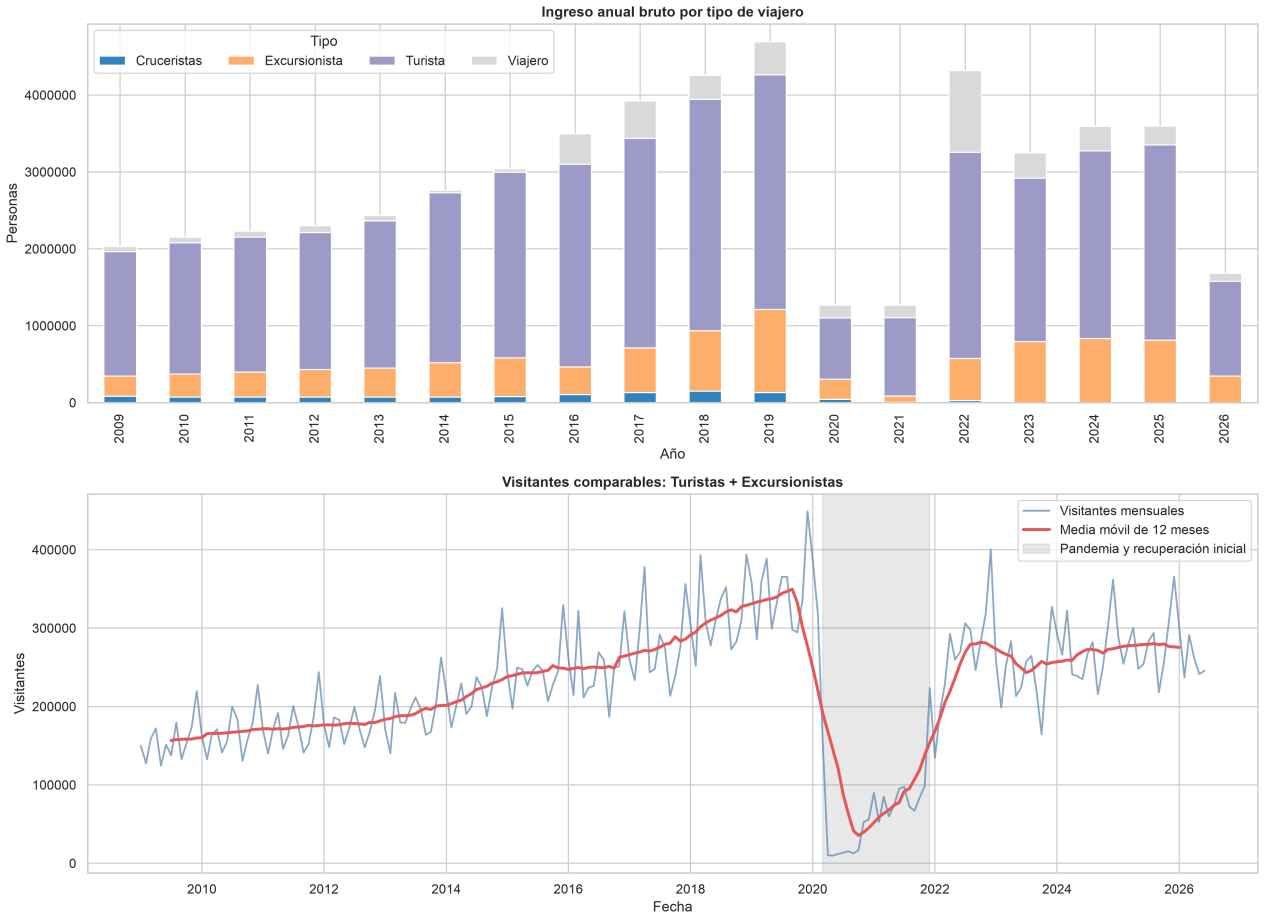


Figura 1. Evolución anual por tipo de viajero y comportamiento mensual de turistas más excursionistas. La zona sombreada identifica la pandemia y la recuperación inicial.

3.2 Principales mercados, regiones, vías y fronteras

Los resultados muestran una fuerte concentración en países centroamericanos y en los ingresos terrestres. El Salvador presenta el mayor volumen acumulado, seguido por Guatemala y Estados Unidos. América del Centro es la región con mayor aporte y la vía terrestre supera ampliamente a las vías aérea y marítima. El Aeropuerto Internacional La Aurora es la frontera individual con mayor volumen.

La presencia de Guatemala en la variable País debe interpretarse de acuerdo con la definición de procedencia o residencia utilizada por la fuente y no necesariamente como turismo receptor de extranjeros.

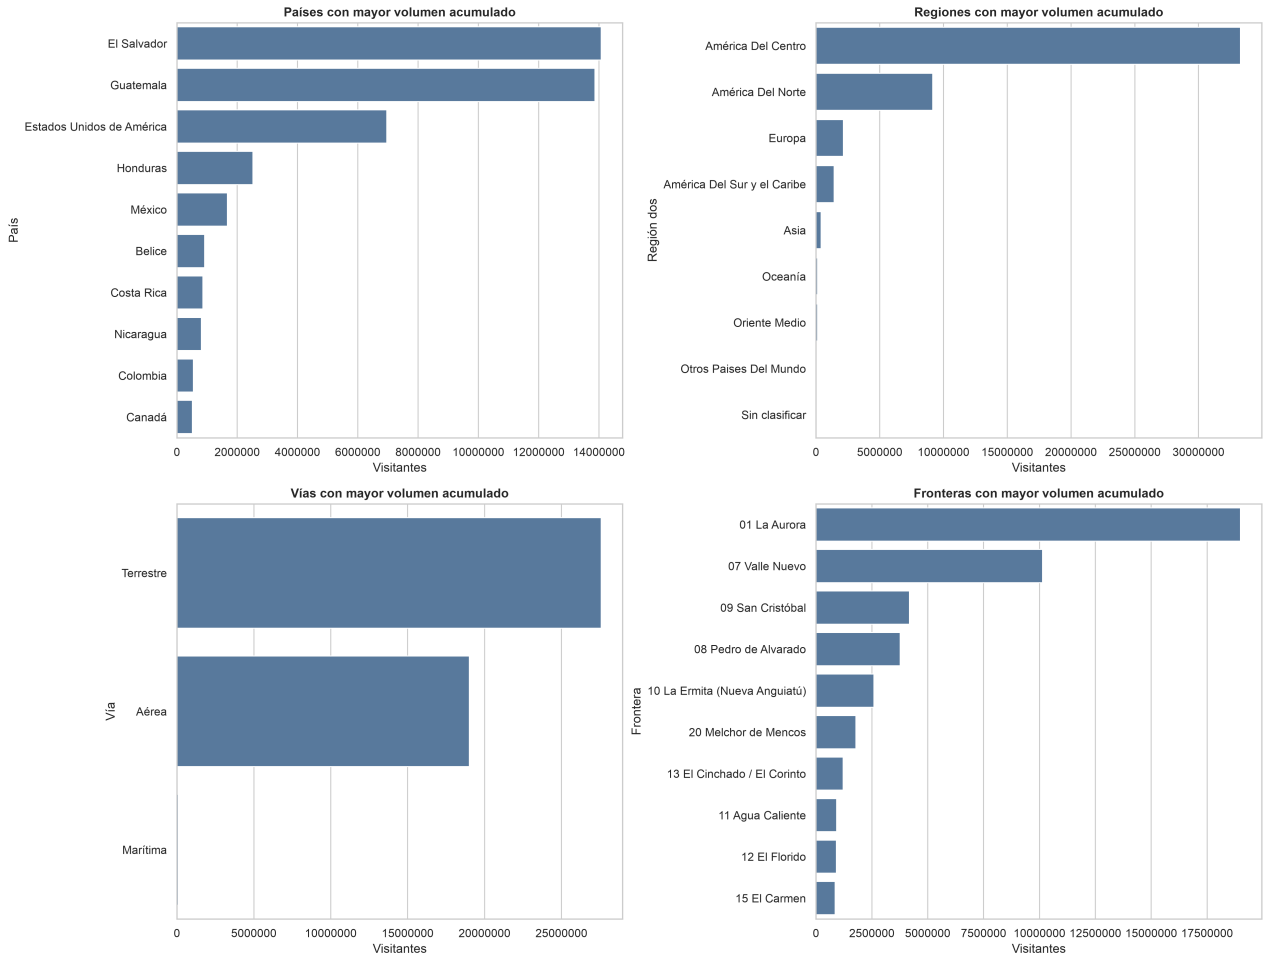


Figura 2. Países, regiones, vías y fronteras con mayor volumen acumulado de visitantes comparables.

3.3 Cruces y patrón mensual

El cruce entre región y vía permite diferenciar los mercados que dependen principalmente de conexiones aéreas de los flujos regionales terrestres. América del Centro se relaciona fuertemente con la vía terrestre, mientras que regiones más lejanas dependen en mayor proporción del ingreso aéreo. El volumen por mes calendario presenta variaciones recurrentes, lo que respalda el uso de una frecuencia estacional de 12 meses.

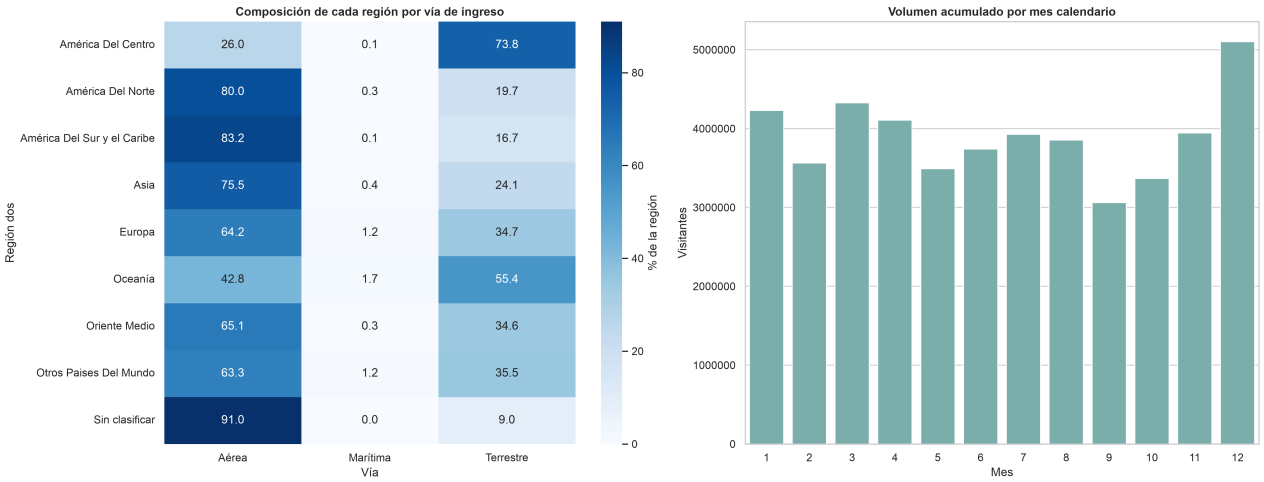


Figura 3. Composición de las regiones por vía de ingreso y distribución acumulada por mes calendario.

4. Construcción de las series y división de datos

Se construyó un índice mensual continuo entre enero de 2009 y junio de 2026. Las categorías seleccionadas fueron Vía y Región dos. Esto produjo siete series:

1. Total de turistas más excursionistas.
2. Vía aérea.
3. Vía terrestre.
4. Vía marítima.
5. América del Centro.
6. América del Norte.
7. Europa.

Todas las series tienen frecuencia mensual y 210 observaciones. La división fue cronológica: las primeras 147 observaciones, desde enero de 2009 hasta marzo de 2021, forman el conjunto de entrenamiento; las 63 observaciones restantes, desde abril de 2021 hasta junio de 2026, forman el conjunto de prueba. No se utilizó una división aleatoria porque habría permitido que información futura influyera en el entrenamiento.

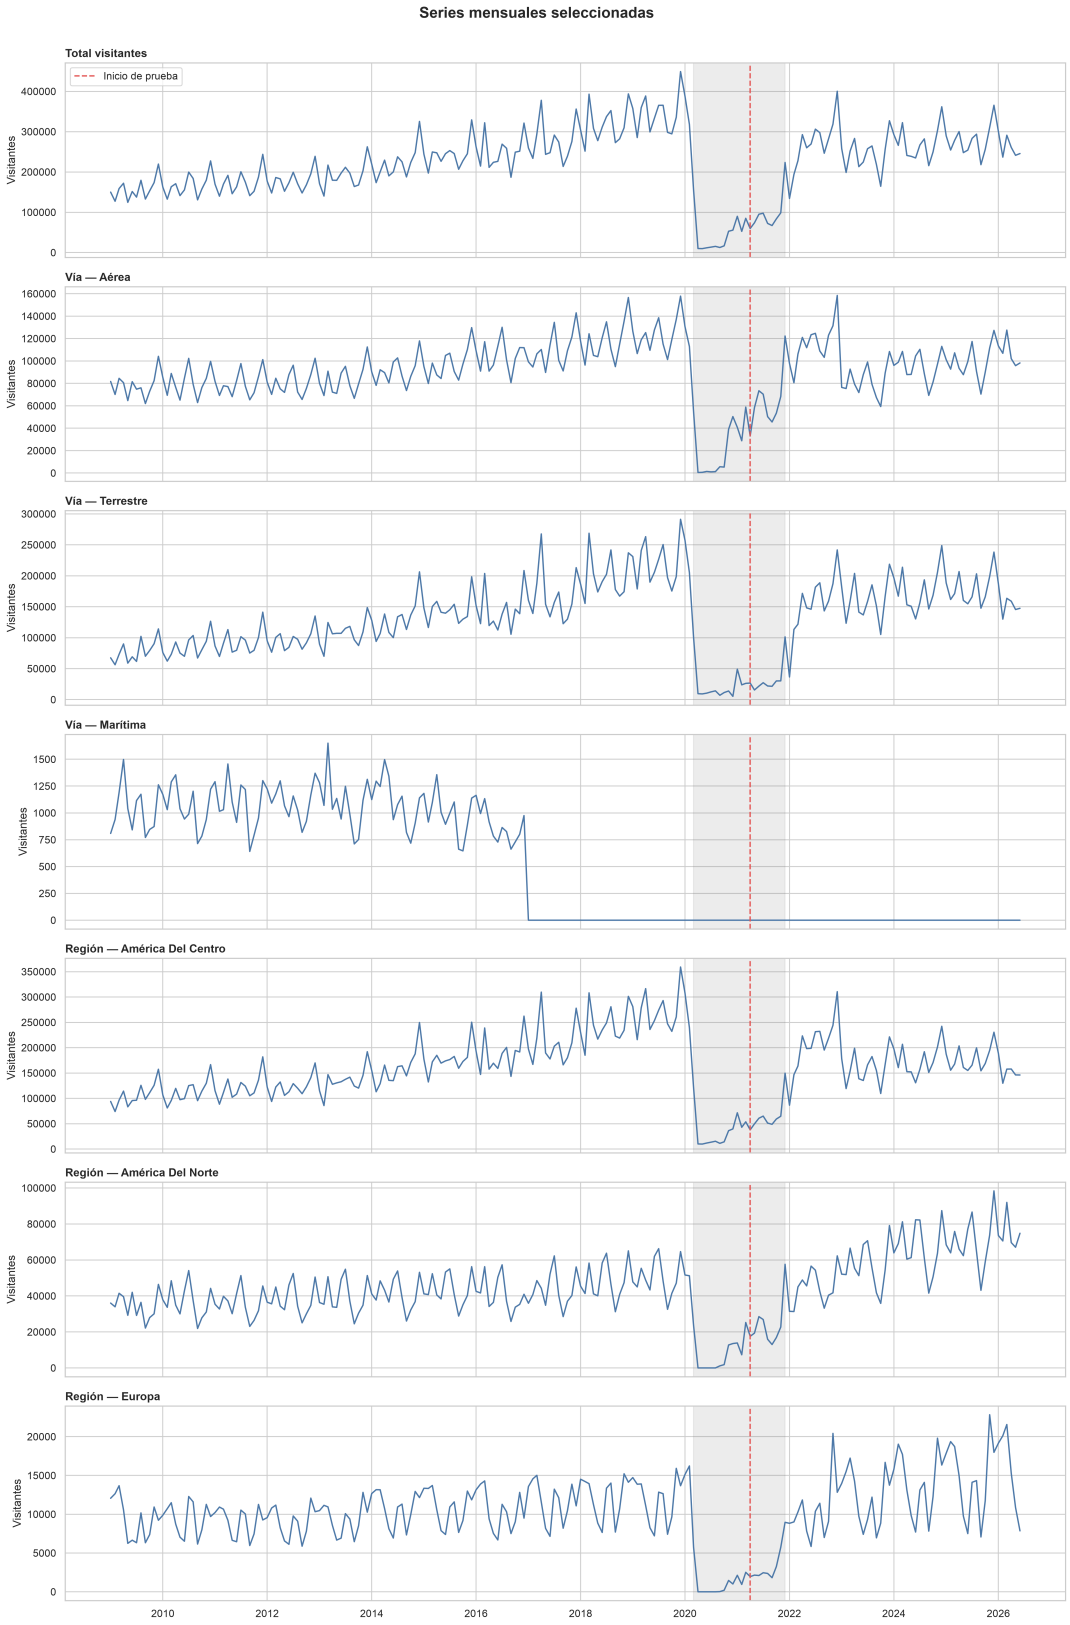


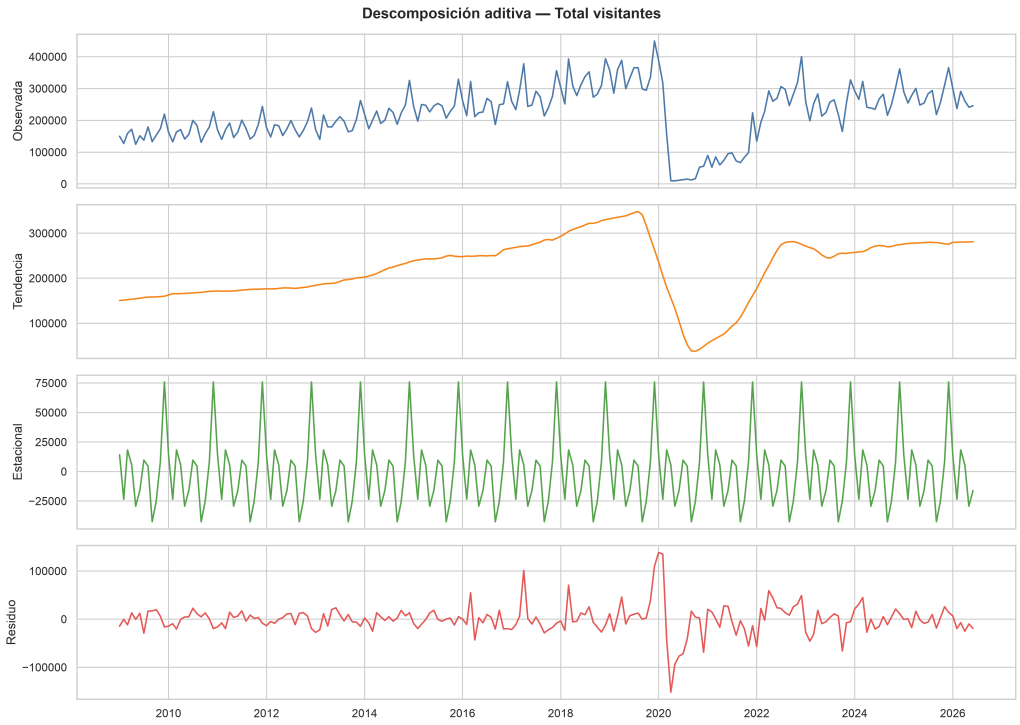
Figura 4. Series mensuales seleccionadas. La línea roja indica el inicio del conjunto de prueba y el sombreado representa la pandemia y recuperación inicial.

5. Análisis de las series

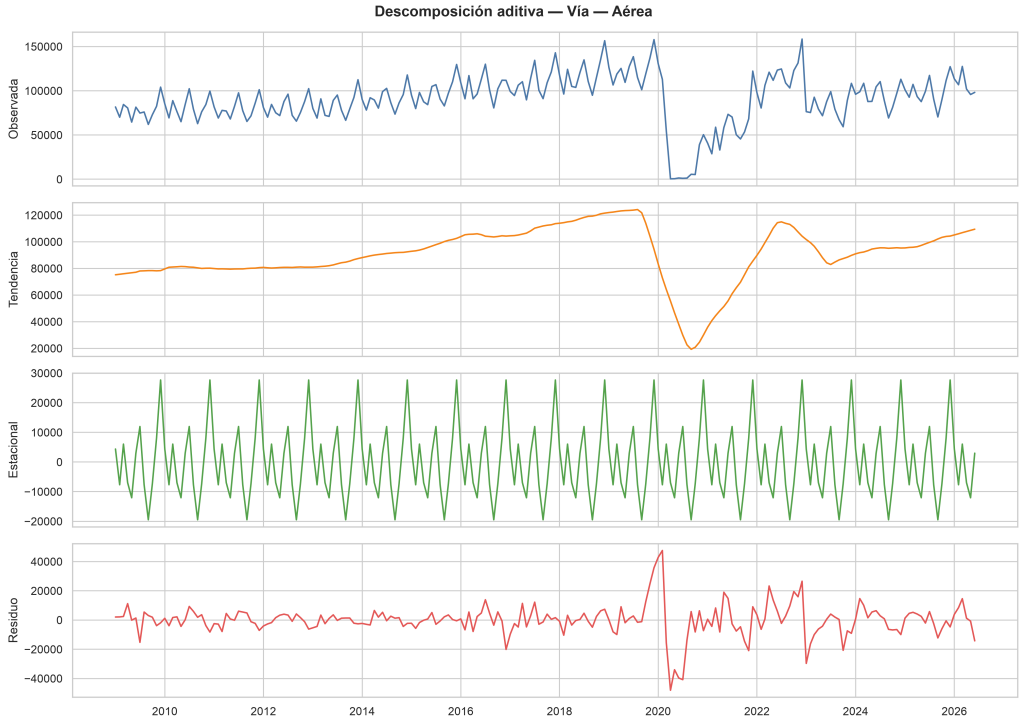
5.1 Tendencia, estacionalidad y descomposición

Las descomposiciones aditivas muestran que las series combinan tendencia, un patrón estacional anual y componentes irregulares. Se eligió el modelo aditivo porque durante la pandemia existen valores cercanos a cero, lo que hace inadecuada una descomposición multiplicativa. Los residuos de gran magnitud alrededor de 2020 confirman que la pandemia constituye una intervención externa que la tendencia y la estacionalidad ordinarias no pueden explicar.

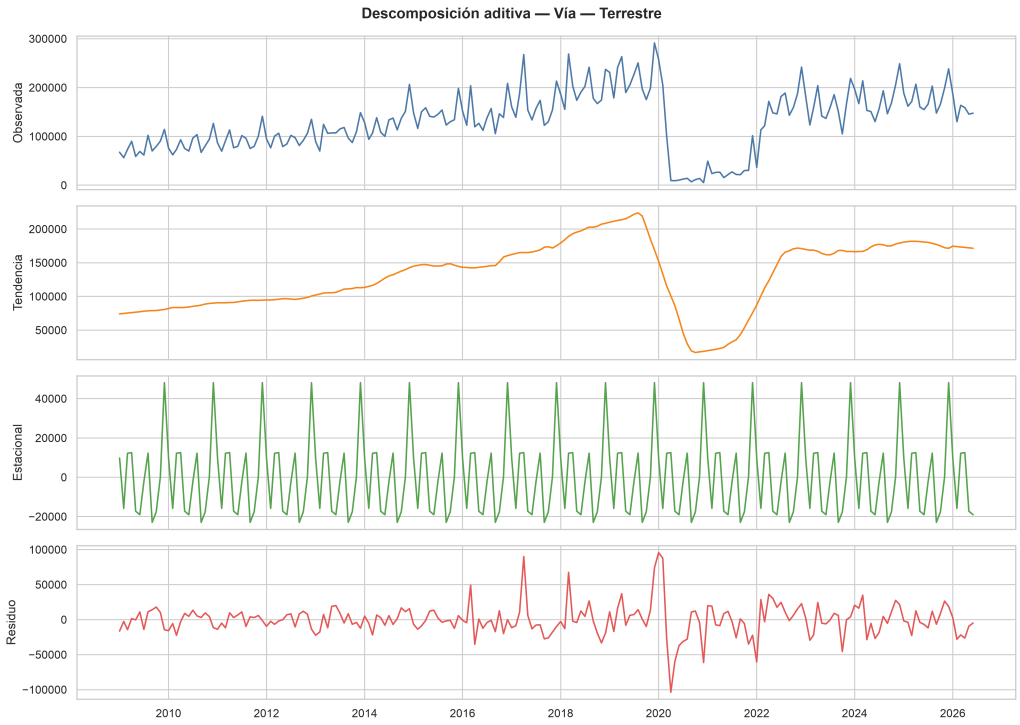
Figura 5. Descomposición aditiva de la serie mensual en observación, tendencia, estacionalidad y residuo (una serie por gráfica).



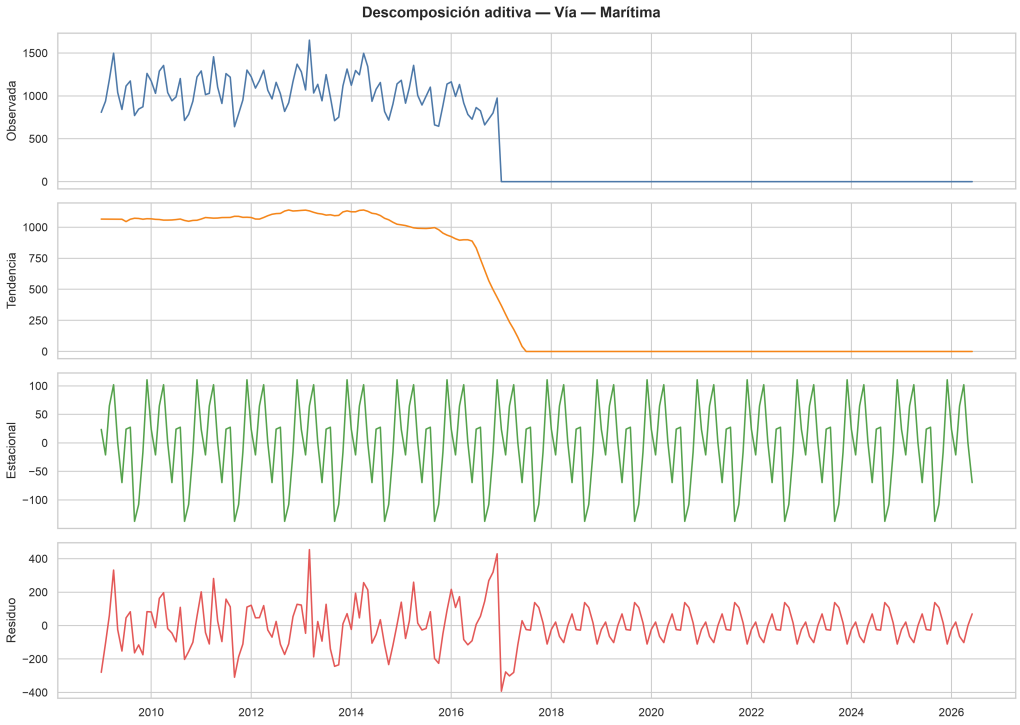
Total de visitantes


Descomposición aditiva — Vía — Aérea
Observada
Tendencia
Estacional
Residuo
2010
2012
2014
2016
2018
2020
2022
2024
2026

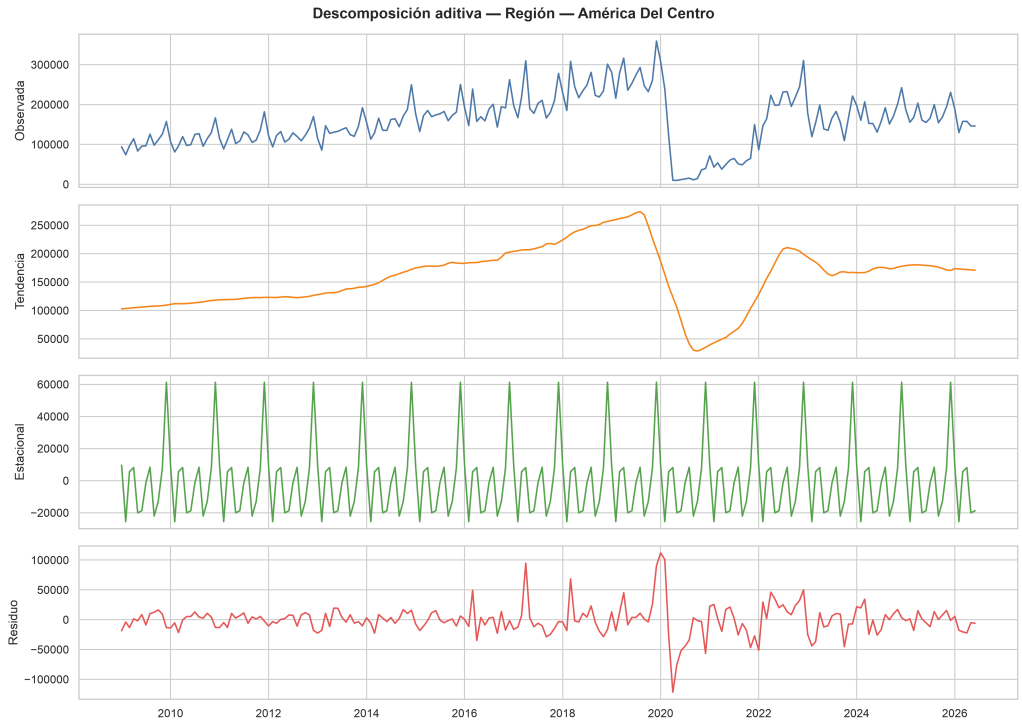
Vía aérea



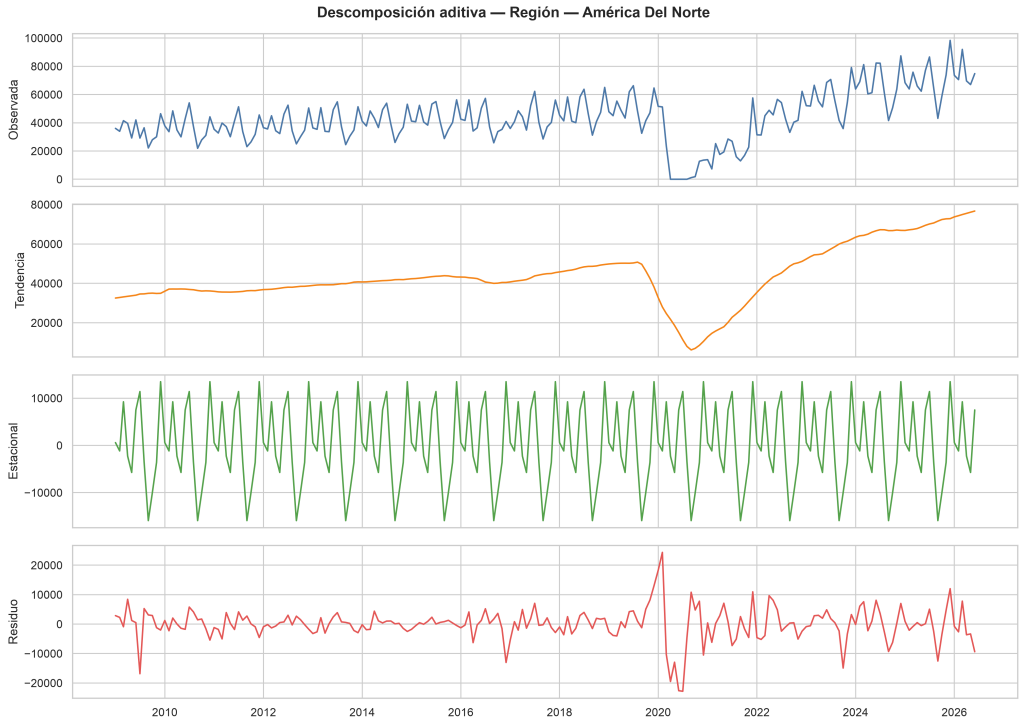
Vía terrestre



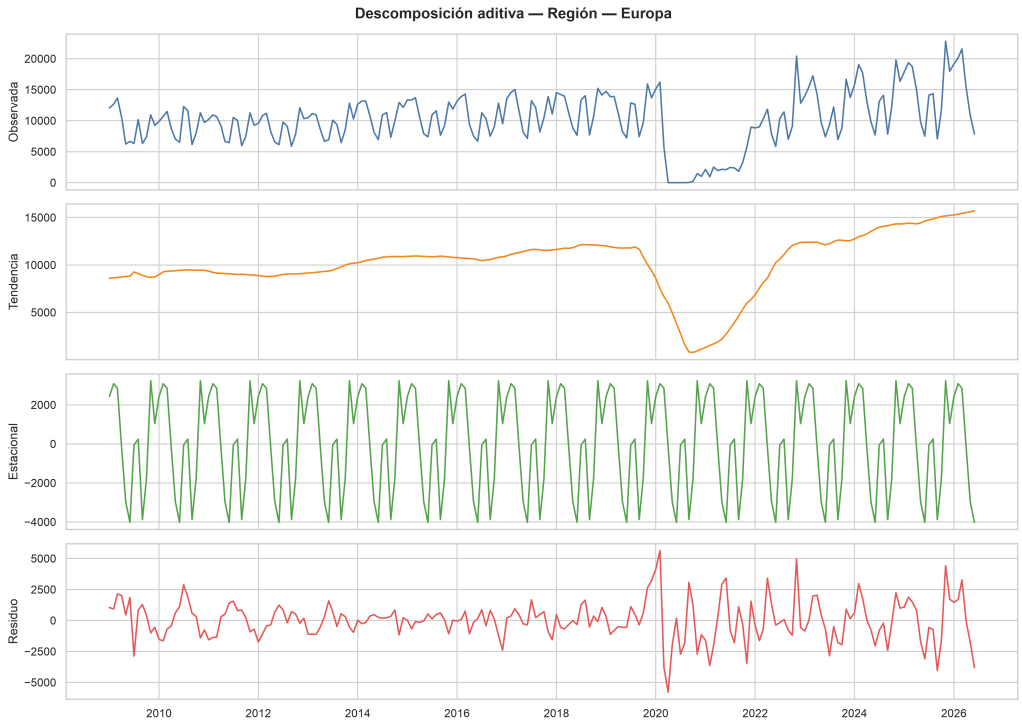
Vía marítima



Región: América del Centro



Región: América del Norte



Región: Europa

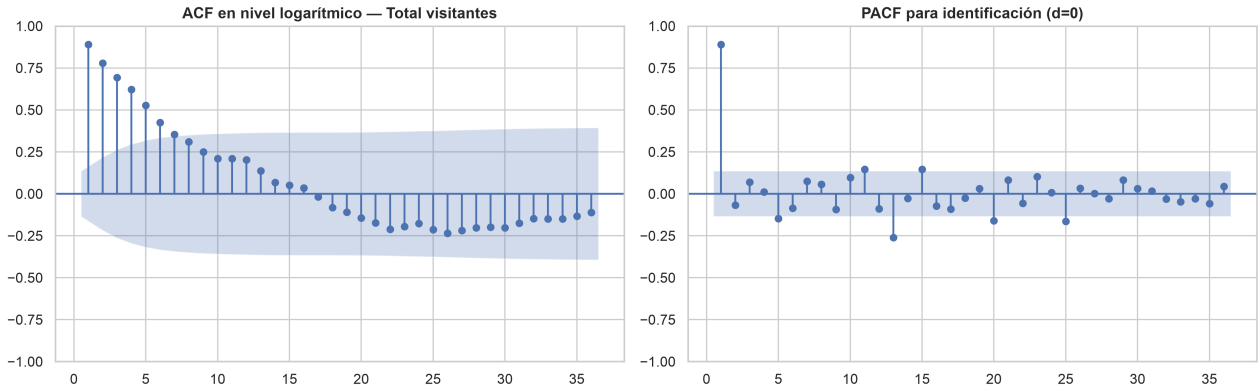
5.2 Estacionariedad en varianza

Las series son conteos no negativos y varias muestran cambios en su dispersión conforme cambia el nivel. Se aplicó la transformación *log1p*, que admite ceros y reduce la influencia de valores grandes. Esta transformación también evita pronósticos negativos al regresar a la escala original.

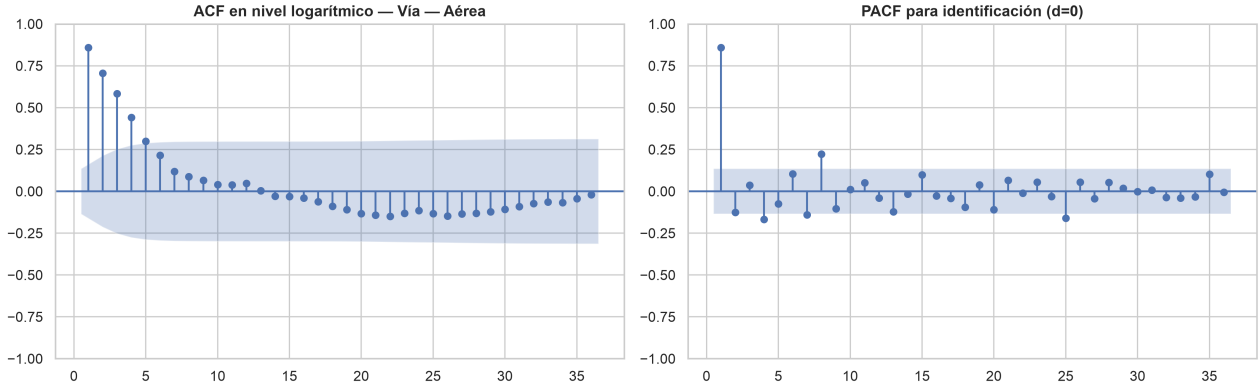
5.3 Estacionariedad en media

La estacionariedad en media se evaluó mediante la función de autocorrelación y la prueba Dickey–Fuller aumentada. Una ACF que disminuye lentamente indica persistencia y posible no estacionariedad. Las series marítima y América del Norte necesitaron una diferencia regular (*d=1*); las demás utilizaron *d=0* después de considerar el diagnóstico conjunto. La dependencia anual observada en los rezagos 12, 24 y 36 justificó una diferencia estacional *D=1* en los modelos SARIMA.

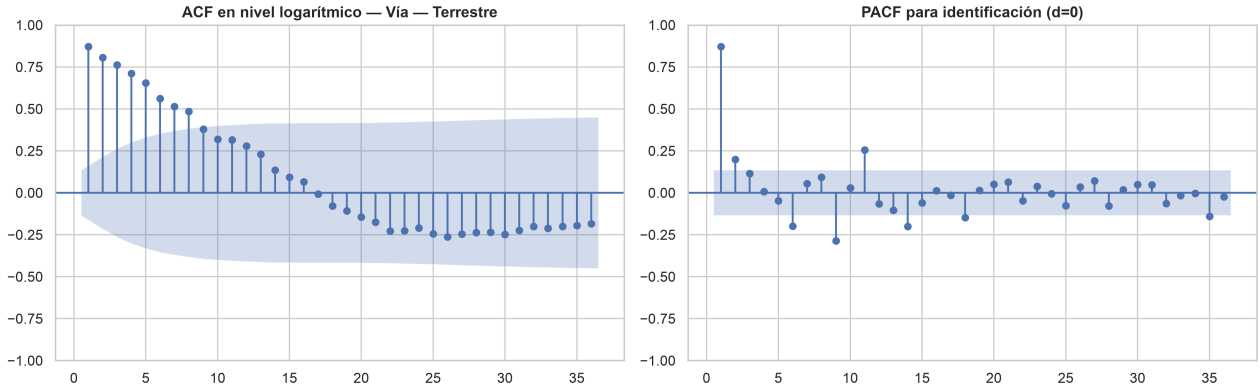
Figura 6. ACF en nivel logarítmico y PACF después de la diferenciación necesaria.



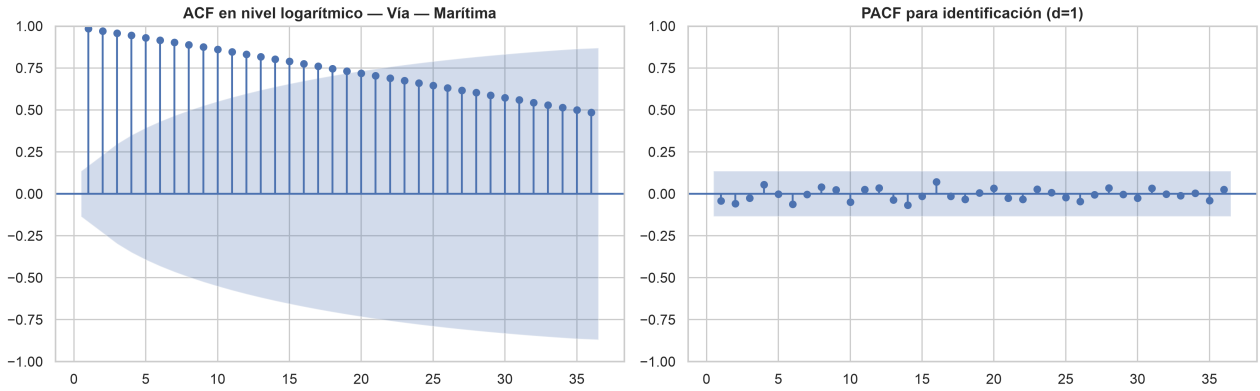
Total de visitantes



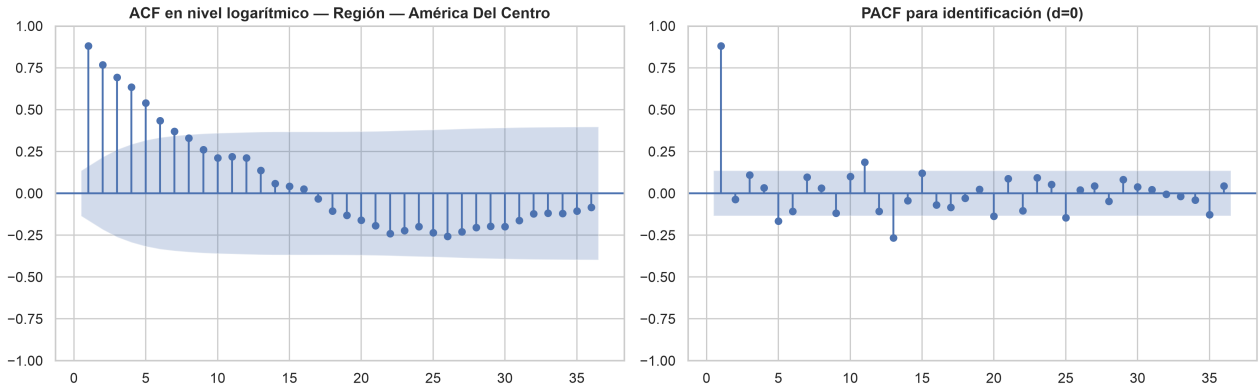
Vía aérea



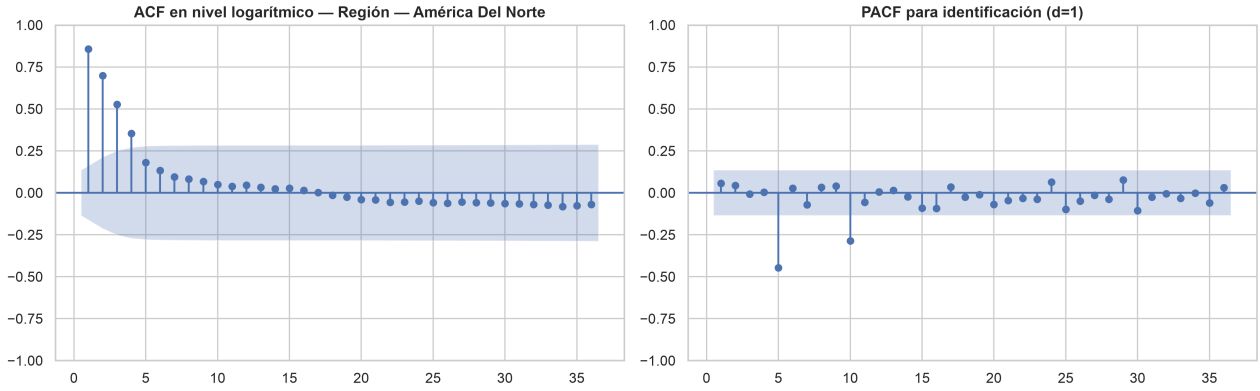
Vía terrestre



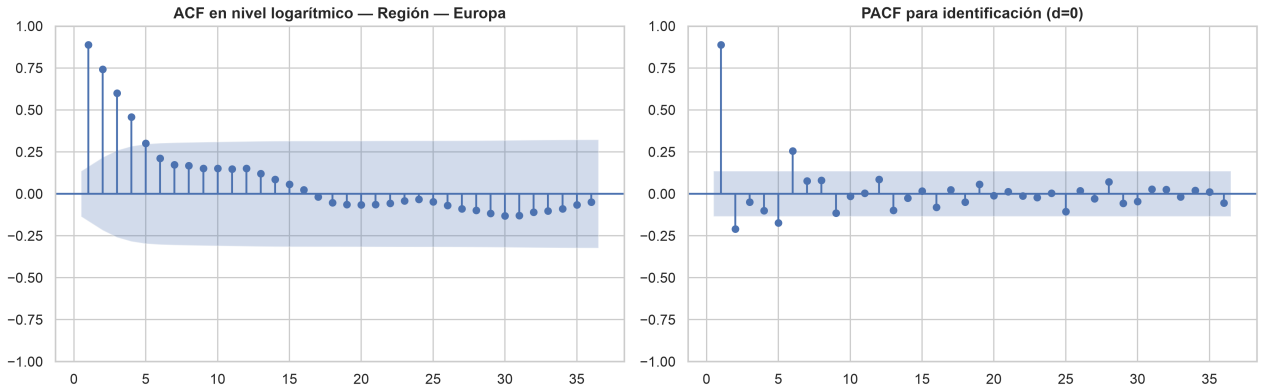
Vía marítima



Región: América del Centro



Región: América del Norte



Región: Europa

6. Modelos ARIMA y SARIMA

Los parámetros *p* y *q* se limitaron a valores pequeños porque las principales correlaciones aparecieron en los primeros rezagos de PACF y ACF. Para cada serie se probaron ocho candidatos: cuatro ARIMA no estacionales y cuatro SARIMA con periodicidad 12. Los modelos se ajustaron sobre *log1p* y se compararon mediante AIC y BIC.

Además de convergencia, se verificó la estabilidad del pronóstico. Se rechazaron trayectorias que excedieran cinco veces el máximo observado en entrenamiento. Este criterio evitó aceptar un modelo de la vía aérea que tenía un AIC favorable, pero generaba valores explosivos a largo plazo.

6.1 Modelos seleccionados

Serie	Modelo seleccionado	AIC	BIC
Total visitantes	SARIMA(1,0,1)(1,1,0)[12]	56.66	67.87
Vía aérea	SARIMA(1,0,1)(0,1,1)[12]	179.43	190.61
Vía terrestre	SARIMA(1,0,1)(1,1,0)[12]	104.97	116.19
Vía marítima	SARIMA(1,1,1)(0,1,1)[12]	253.74	264.89
América del Centro	SARIMA(1,0,1)(1,1,0)[12]	46.97	58.19
América del Norte	SARIMA(1,1,2)(0,1,1)[12]	373.44	387.33
Europa	SARIMA(1,0,2)(0,1,1)[12]	313.64	327.58

Tabla 1. AIC y BIC del modelo SARIMA seleccionado por serie.

AIC y BIC solo fueron comparados entre modelos de la misma serie, transformación y muestra. No se utilizaron para comparar ARIMA con Prophet o suavizamiento exponencial.

6.2 Diagnóstico de residuos

Después de descartar el período de inicialización, seis de los siete SARIMA seleccionados presentaron valores Ljung–Box mayores que 0.05 y residuos aproximadamente centrados en cero. América del Norte fue la excepción, con $p=0.0043$, lo que indica autocorrelación residual y posibilidad de mejora.

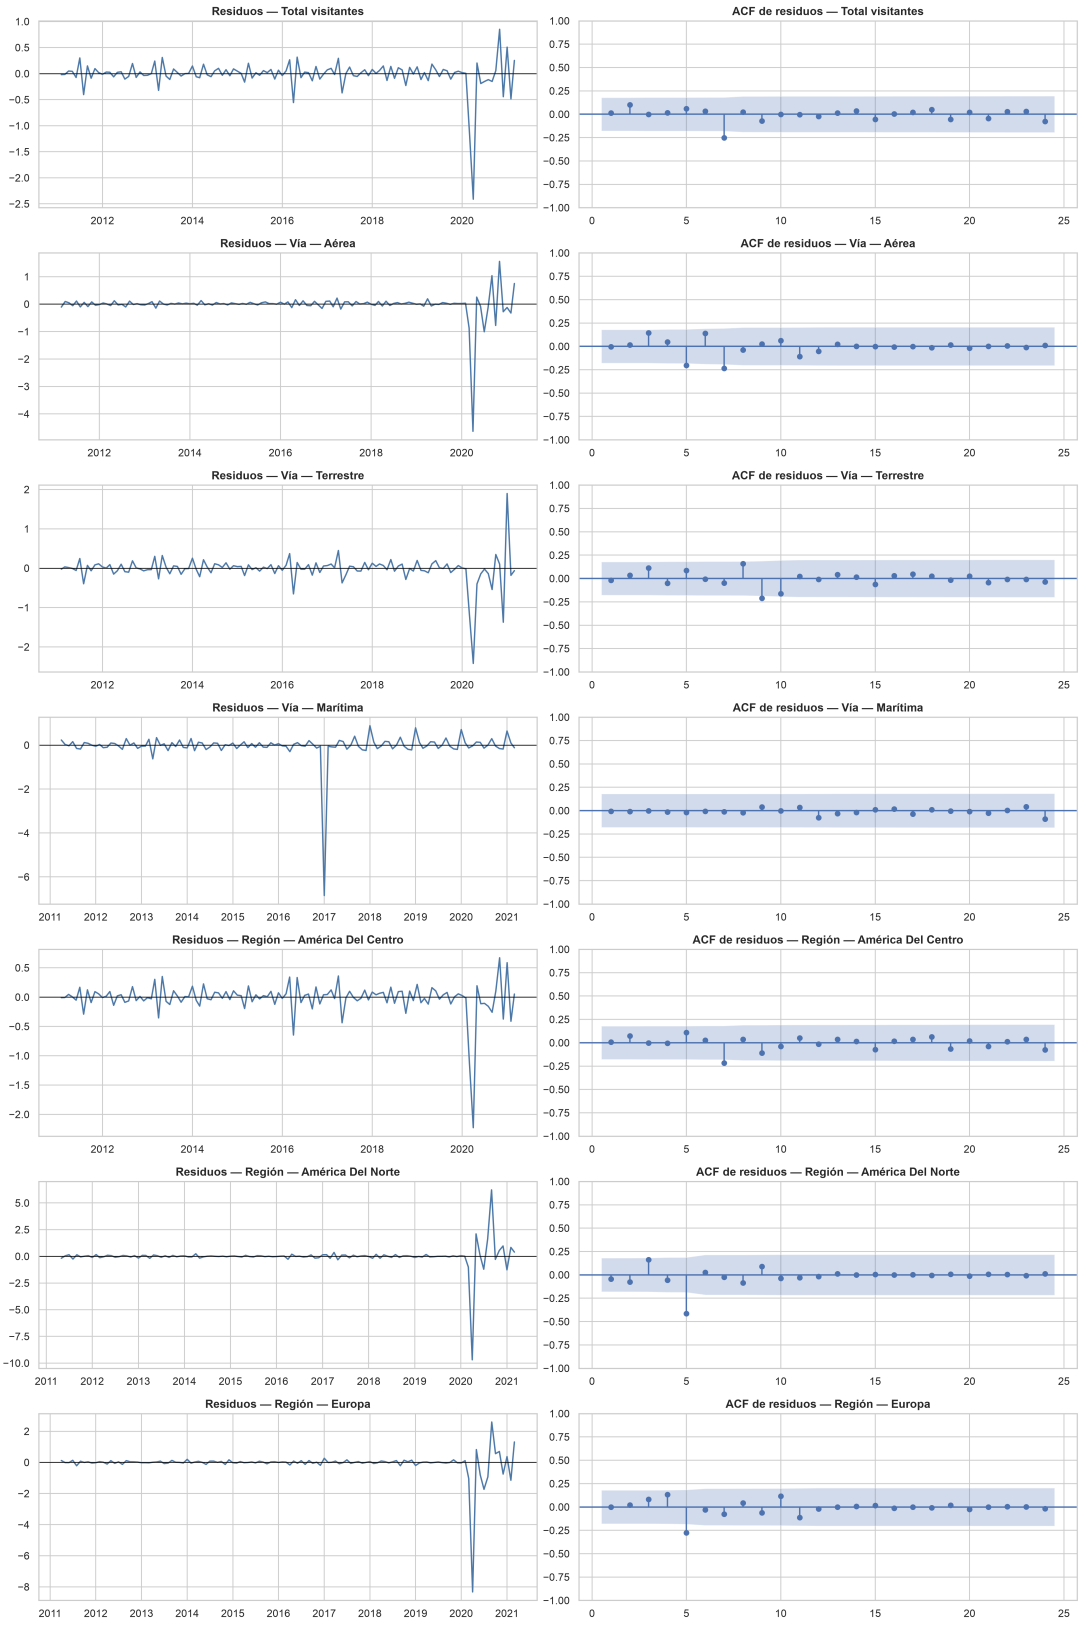


Figura 7. Residuos y autocorrelación residual de los modelos SARIMA seleccionados.

7. Modelos alternativos y predicción

Cada SARIMA seleccionado se comparó con cuatro alternativas:

- Seasonal naïve, que repite el valor del mismo mes del último año.
- Suavizamiento exponencial simple, que actualiza únicamente el nivel.
- Holt–Winters aditivo, con tendencia amortiguada y estacionalidad anual.
- Prophet, con tendencia por tramos y estacionalidad anual.

La evaluación se realizó sobre los 63 meses de prueba. MAE representa el error absoluto promedio en personas y RMSE penaliza con mayor fuerza los errores grandes. El menor RMSE determinó el modelo ganador.

7.1 Resultados

Serie	Mejor modelo	MAE	RMSE
Total visitantes	Suavizamiento exponencial	165,373	180,598
Vía aérea	Suavizamiento exponencial	36,971	42,141
Vía terrestre	Suavizamiento exponencial	121,715	134,136
Vía marítima	Seasonal naïve	0	0
América del Centro	Holt–Winters	108,192	117,775
América del Norte	Holt–Winters	40,351	43,885
Europa	ARIMA/SARIMA	9,998	10,946

Tabla 2. Mejor modelo por serie según MAE y RMSE sobre el conjunto de prueba.

El resultado marítimo requiere cautela: la serie de turistas más excursionistas contiene ceros durante todo el conjunto de prueba bajo la cobertura disponible. El error cero no demuestra ausencia real de actividad marítima, sino que refleja el cambio de fuente y metodología.

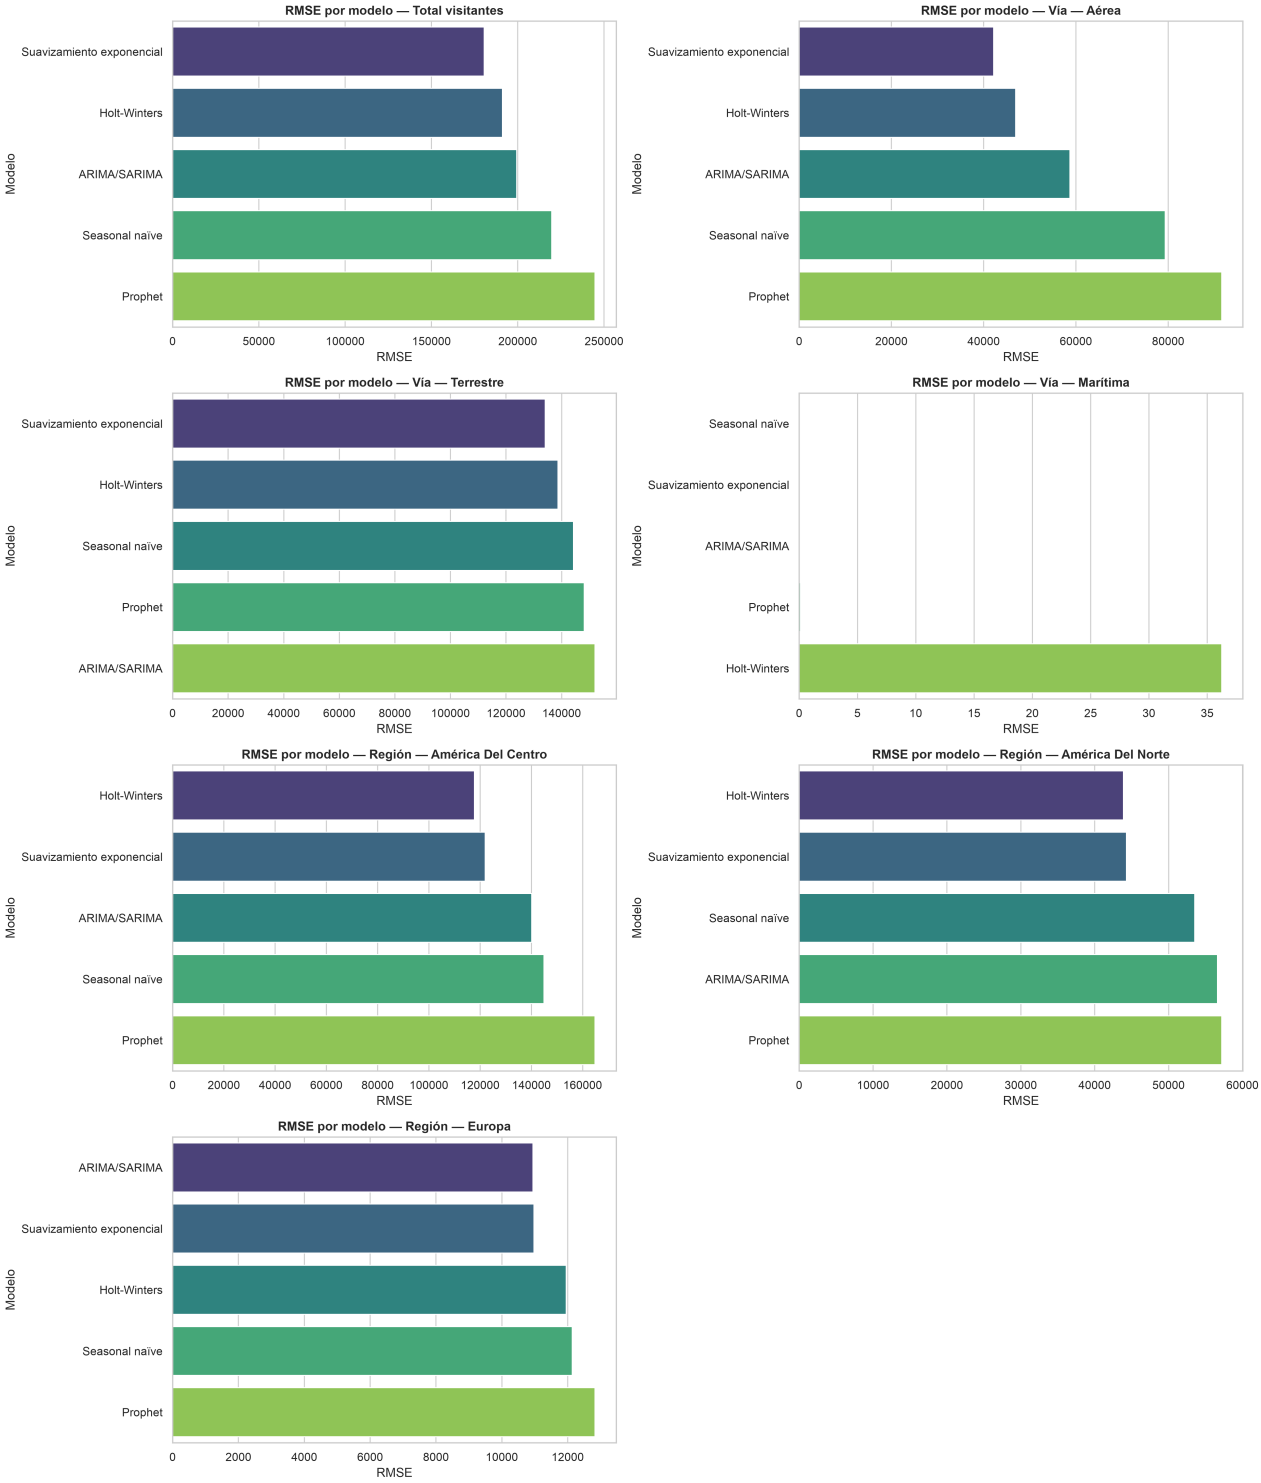


Figura 8. Comparación del RMSE de los cinco métodos para cada serie.

7.2 Calidad de los pronósticos

El horizonte de prueba es especialmente difícil porque el entrenamiento termina en marzo de 2021, cerca del nivel pandémico, y la prueba contiene la reapertura y recuperación hasta 2026. En el total y las vías terrestre y aérea, el suavizamiento exponencial supera a modelos más complejos porque evita extrapolar

agresivamente las condiciones anormales del final del entrenamiento. Holt–Winters funciona mejor para América del Centro y América del Norte, donde el patrón estacional aporta información útil. Europa es la única serie donde ARIMA/SARIMA obtiene el menor RMSE.

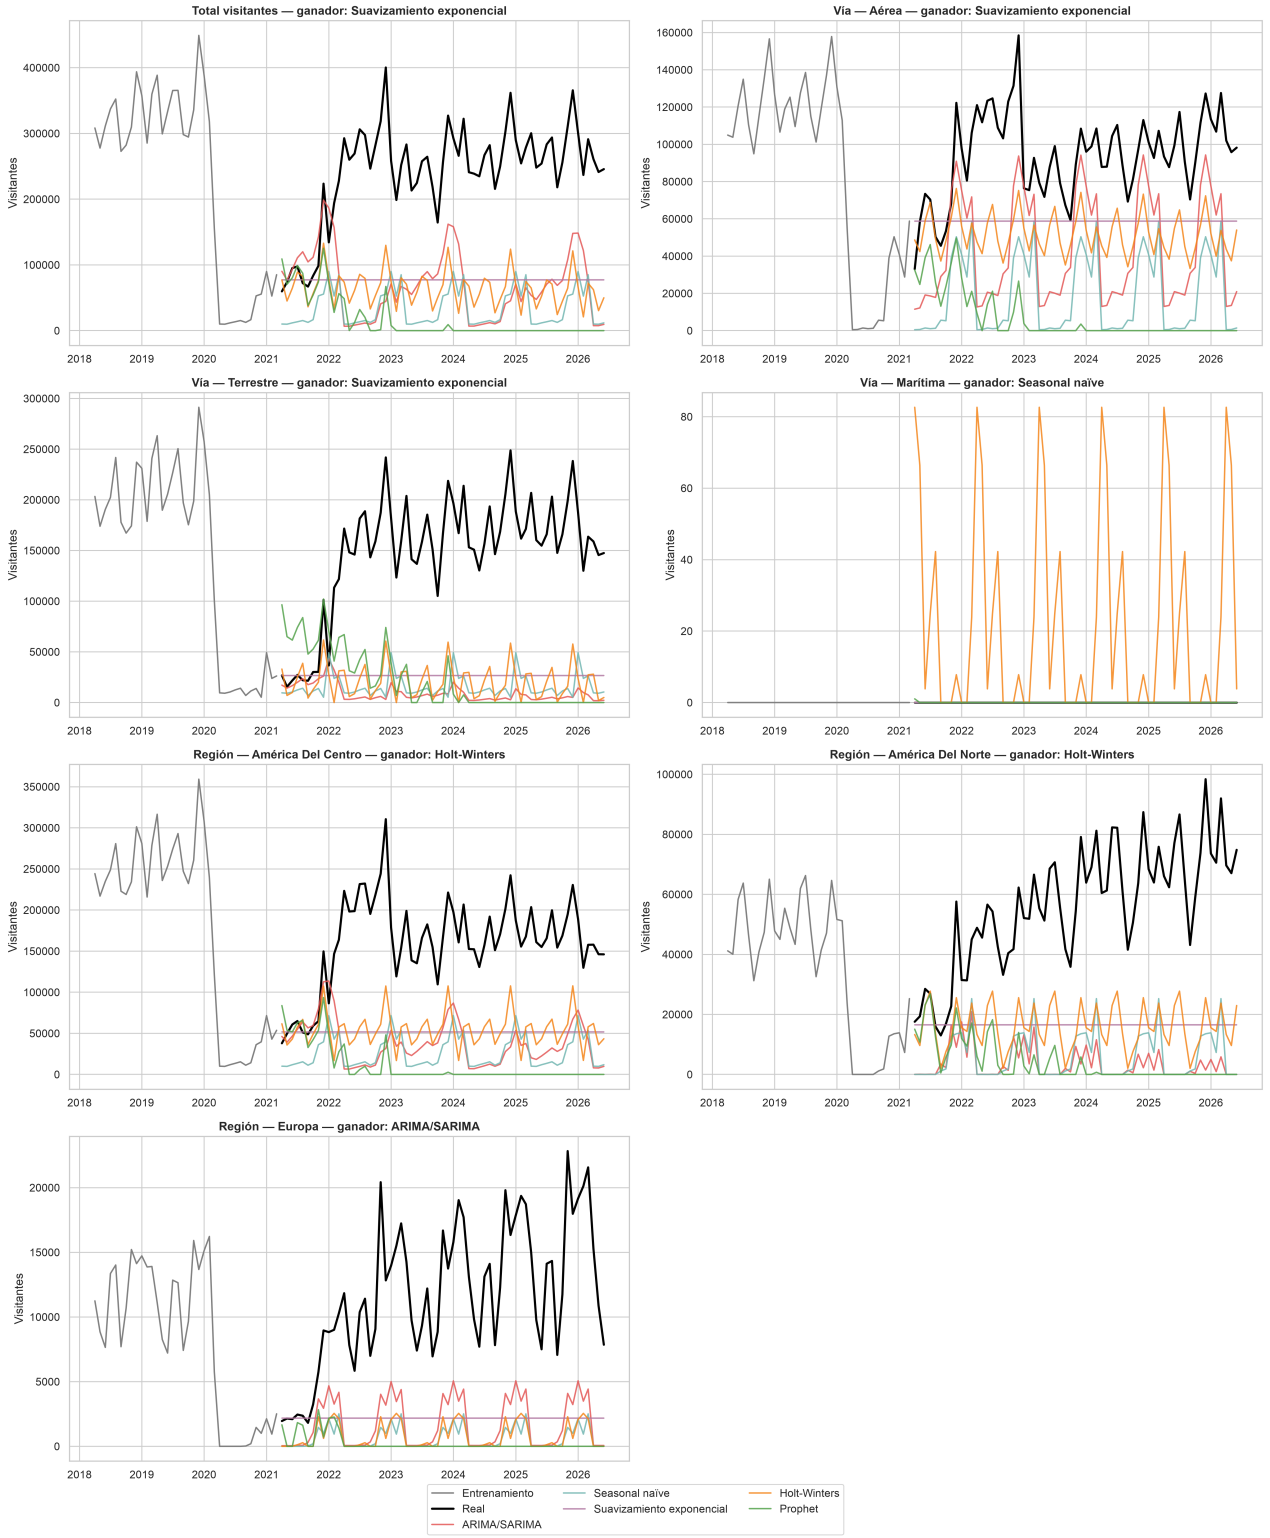


Figura 9. Valores reales del conjunto de prueba y pronósticos producidos por los cinco métodos.

8. Análisis comparativo

La fuerza estacional se calculó a partir de la proporción de varianza explicada por el componente estacional; la tendencia se representó mediante la pendiente mensual previa a 2020; la volatilidad mediante la desviación de los cambios porcentuales; y el efecto pandémico mediante el cambio entre los totales de 2019 y 2020.

Entre las vías, la aérea presenta la mayor fuerza estacional. La terrestre muestra el mayor crecimiento absoluto antes de 2020, la mayor volatilidad relativa y la mayor reducción durante la pandemia entre las vías comparables.

Entre las regiones, Europa presenta la mayor estacionalidad y volatilidad. América del Centro registra el mayor crecimiento absoluto previo a 2020 y la mayor caída pandémica.

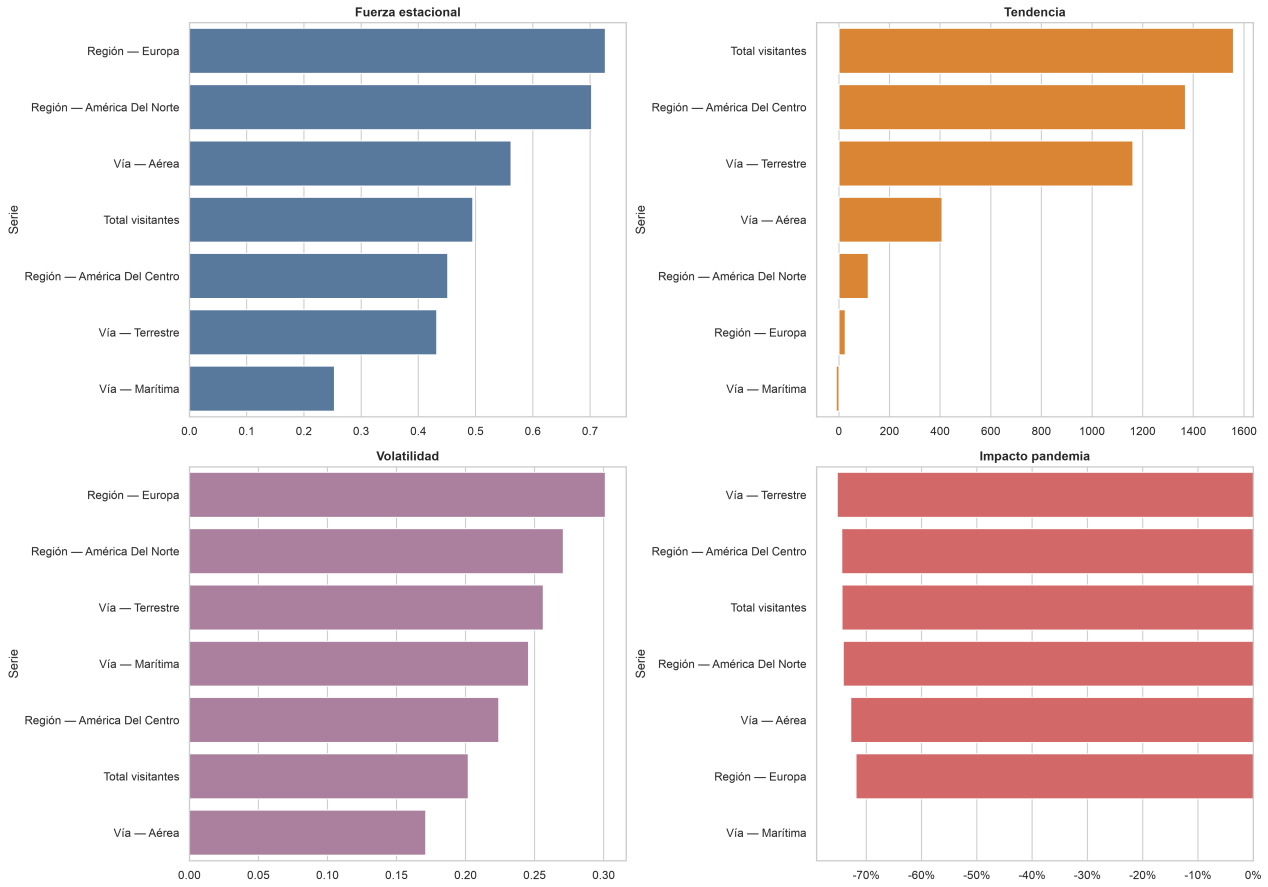


Figura 10. Comparación estadística de estacionalidad, tendencia, volatilidad e impacto de la pandemia.

9. Hallazgos útiles para INGUAT

1. La concentración terrestre y centroamericana justifica priorizar capacidad operativa, información turística y coordinación en los principales pasos fronterizos.

2. La estacionalidad permite anticipar meses de mayor demanda y distribuir campañas, personal e infraestructura antes de los picos.
3. Los mercados aéreos y europeos presentan patrones diferentes de los flujos regionales terrestres, por lo que requieren estrategias de promoción diferenciadas.
4. Los pronósticos deben actualizarse mensualmente y compararse siempre con una línea base sencilla como seasonal naïve.
5. Conviene construir escenarios alternativos porque una pandemia, un cambio de fuente o una modificación regulatoria puede producir errores mayores que las diferencias normales entre modelos.

10. Limitaciones

- Los datos son exclusivamente académicos y no corresponden a cifras oficiales.
- El conjunto de prueba contiene una recuperación extraordinaria que no podía observarse durante el entrenamiento.
- Desde 2023 existen cambios en la clasificación de Viajero, cruceros, país y vía marítima.
- La serie marítima comparable tiene cobertura limitada y no debe interpretarse como un conteo completo de actividad portuaria.
- Prophet y los modelos de suavizamiento no proporcionan AIC/BIC directamente comparables con SARIMA; por eso la comparación final se basa en MAE y RMSE.

11. Conclusiones

El análisis confirmó que el ingreso de visitantes a Guatemala no es estacionario en un sentido simple: combina crecimiento, estacionalidad anual, diferencias entre mercados y una ruptura histórica causada por la pandemia. La vía terrestre y América del Centro concentran el mayor volumen, mientras que Europa exhibe el patrón estacional y la volatilidad relativa más fuertes.

La comparación predictiva demostró que un modelo complejo no siempre produce mejores resultados. El suavizamiento exponencial fue superior para el total y las principales vías, Holt–Winters para dos regiones y SARIMA para Europa. Esto respalda la selección individual por serie y el uso conjunto de diagnósticos internos, estabilidad y error fuera de muestra.

Para un uso operativo, los modelos deben reentrenarse conforme se incorporen nuevos meses y deben acompañarse de escenarios que consideren cambios metodológicos o eventos extraordinarios.